


文章を生成しない AI「Jev」は、使えるのか？

判断だけを任せる AI を オセロと問い合わせ振り分けで 検証してみた

Jev とは何か、GPTと比べてどうだったか、
どこに組み込むと効くのか。何に組み込むのがベストか。

社内エンジニア会（10月1日）

2 週間前に発表され、いま話題の AI「Jev」



9/15 元 OpenAI の研究者が創業した TypeSafe AI が発表
出典：TypeSafe AI 公式ブログ（2026/9/15）

9/18 開発者が殺到して API が一時パンク。Vercel では 5～18 倍速になったと報道
出典：TechCrunch（2026/9/18）

9/24 評価額 100 億ドル超の調達を協議中と報道
出典：The Information（2026/9/24、交渉中で未確定）

Jev は、文章を生成しない「評価モデル」

文章は書かず、渡した選択肢の中から**確率つきで選ぶ**だけ。渡すものは3つ。

state : 判断の対象（問い合わせ文）

instructions : 何を基準に選ぶか（質問文）

criteria : 選択肢と、それぞれの短い説明

右は実際のリクエストを簡略化したもの（実際の instructions と criteria は英語で、もう少し長い）。questions に department と urgency の2問を並べ、どちらも同じ3点セット

```
// リクエスト
experimental_evaluate({
  model: 'typesafe-ai/jev',
  state: { inquiry: '請求画面を開くと真っ白になって何も表示されません。' },
  questions: {
    department: {
      type: 'choice',
      instructions: 'Which team should handle this?',
      criteria: { billing: '既存契約のお金', technical: '製品が動かない',
        ... }
    },
    urgency: {
      type: 'choice',
      instructions: 'How urgently does this need a response?',
      criteria: { high: '今日中', normal: '数日以内', low: '急がない' }
    },
  }
})
```

レスポンス：文章ではなく、確率と自信が返る

```
// レスポンス
{
```

```
  department: {
    choice: 'technical',
    probabilities: {
      technical: 0.98, billing: 0.02,
    },
    confidence: 0.98
  },
```

```
  urgency: {
    choice: 'high',
    probabilities: {
      high: 0.67, normal: 0.33, low: 0 },
    confidence: 0.49
  },
```

```
}
```


choice：選ばれた選択肢（確率が最大のもの）

probabilities：選択肢ごとの確率。迷いの内訳が見える

confidence：判断への自信（0～1）。確率が割れるほど低い

緊急度は迷っている（confidence 0.49）

high  **0.67**

normal  **0.33**

部署は 0.98 で即断、緊急度は 0.49 で迷い。この値で「自動で処理／人に回す」を分けられる


一般的な LLM との違い： 答えをそのまま分岐に使える



今回検証してみたこと：性質の違う 2 つの題材


オセロ

ゲームの決まりが明確なので、合法手・返せる枚数などの判断材料をコードで正確に計算できる。その合法手の中から 1 手を選ばせる



問い合わせの振り分け

自然文の意味を読む必要がある。担当部署（5 択）と緊急度（3 択）を選ばせる



比較相手は GPT（gpt-5-mini）と、オセロでは人が if 文で書いた打ち手、問い合わせではキーワードルール。全リクエストとレスポンスをログに残し、画面で 1 件ずつ確認できるようにした

先に結論：「どの判断を誰に任せるか」が重要

① 条件がはっきり決まる判断は、AI ではなくコードで

例：金額が 10 万円以上なら承認へ、本文が空なら人へ。単語から意味を推測するのはここに入らない

② 文章の意味を読まないといけない判断は、Jev に

例：この問い合わせは怒っているか、どの部署宛か。GPT と同等以上の正解率で、11 倍速く 27 分の 1 のコスト

③ Jev の自信（confidence）が低い判断は、人が確認する

例：confidence 0.5 未満は担当者の確認キューへ。GPT に回しても正解率は上がらなかった

まず速さとコスト：これは間違いなく速くて安い

オセロ 1 手あたりの時間（中央値。Jev 453 手・GPT 220 手）

Jev 0.34 秒

GPT 25.7 秒

約 75 倍

オセロ 1 手あたりのコスト（平均。Jev 453 手・GPT 220 手）

Jev \$0.000036

GPT \$0.0054

約 150 倍

GPT（gpt-5-mini）の出力トークンは中央値 2,597 で、ほぼ内部推論。終盤は 16,000 に膨らみ 1 手 2 分以上かかることも。問い合わせ振り分け（100 件）でも約 11 倍速く、コストは約 27 分の 1 だった

問題は「賢さ」。速くて安くても、判断の質が伴わなければ使えない

題材 1

オセロ：
ルールで書ける問題で、Jev はどこまでやれるか

Jev が迷ったら GPT に聞く、は効かない

期待：Jev は速いが迷う手がある。confidence が低い手だけ、じっくり考える GPT に任せれば強くなるはず

測り方：3 方式それぞれを、共通の対戦相手（if 文で書いた打ち手）と10戦対局させる

勝敗だけを見ると…


Jev だけ **2 勝 8 敗**

迷ったら GPT **0 勝 10 敗**

GPT だけ **1 勝 9 敗**

どれも負け越し。差はよく分からない

終局時の総石数に占める、相手の石の割合



黒 = 自分の石、白 = 相手の石。10 局の平均石差から換算

「迷ったら GPT」は confidence 0.4 未満の手を GPT に任せた（251 手中 149 手）。

わかったこと：GPT に任せた分だけ、相手の石の割合が増えた。「迷ったら別の AI」は解決策にならない

先読みの情報を足しても、Jev は良くならない

試したこと：Jev に渡す各手の説明文（criteria）に、コードで計算した先読みの情報を足して、強くなるか見た

// 基本情報だけ（124 文字）

c1: '辺のマス。2 枚返す。打った後の相手の手数は 13'

// 先読みを足す（305 文字）

c1: '... + 相手に隅を渡さない。確定石 +0。2 手先の自分の手数 5。打った後の石数 23 対 12'

相手：先読み情報を使う if 文の打ち手。if 文どうしなら、先読み情報を足した側が 28 勝 12 敗で石の 61% を取る（情報自体には価値がある）

終局時の総石数に占める相手の石の割合（各 20 局）


基本情報だけ



相手 56%

返す枚数・マスの種類・相手の手数


基本情報 + 先読み情報を 1 つ（4 通り）



相手 62~65%

確定石 / 隅を渡すかの警告 / 2 手先の手数 / 打った後の石数

基本情報 + 先読み情報 4 つ全部



相手 63%

上の 4 つを同時に入れた長い criteria

黒 = Jev の石。どれも改善せず、やや悪化の傾向（個々の差は誤差の範囲。標準誤差は約 5 ポイント）。割合は平均石差から 64 石として換算

わかったこと：情報には価値があるのに、Jev はそれを勝ちにつなげられない

criteria に数字を入れると、Jev は「大きいほど良い」と読んでしまう

Jev が「一番多く石を返す手」を選んだ割合

53% → 79%

基本情報だけ → 石数を足したとき。

「避けよ」と指示しても


6% → 2%

隅を渡す手の選択。減るが 0 にはならない → 絶対に守らせたい制約は、指示ではなくコードで

元からある情報も使い続けている（相手の手数が最小になる手を選ぶ割合は 51～62% で変わらず）。足した数字にも反応するが、どれが重要かの重み付けができていない

組み込みへの示唆：重み付けと比較はコードで済ませ、Jev には短い言葉の説明だけ渡す

実例：31 手目、e2 を 80% で選択



e2: '6 枚返す・内側のマス・相手の手数 11・隅は渡さない・確定石 +0・2 手先の自分の手数 5・打った後の石数 27 対 8'

c2: '4 枚返す・...・石数 25 対 10' f3: '5 枚返す・...・石数 26 対 9'

7 手とも同じ構造で、違うのは数字だけ。返す枚数と石数が最大の e2 に 80% (c2 7%、f3 6%)。他の数字にはほとんど差がなく、石数の大小が効いている様子が見える (全体では、石数を足すと最多反転の手を選ぶ割合が 53% → 79%)

Jev には判断済みの言葉だけ渡す

オセロの場合

Before : 数字をそのまま渡す

```
e2: '6 枚返す・相手の手数 11・石数 27 対 8'  
b2: '1 枚返す・相手の手数 12・石数 22 対 13'
```

After : コードで全候補を比べ、結果を言葉にする

```
e2: '相手の打てる場所を最も減らす手。隅は渡さない'  
b2: '相手に隅を渡す危険な手'
```

「11」が良いか悪いかは他の手と比べないと分からない。その比較をコードが済ませる

業務アプリの場合（例）

Before : 数字をそのまま state に入れる

```
customer: '契約金額 1,200,000 円・利用 3 年'
```


After : コードで判定してラベルにする

```
customer: '大口顧客・長期利用'
```

問い合わせ振り分けは短い言葉だけの criteria で部署 95% だった（ただし題材が違うので、数字との直接比較ではない）

今回分かったのは「数字を足しても良くならなかった」まで。After の形で良くなるかは未検証で、ここはそこからの推奨

負けても、confidence は信頼できる



Jev の 1,991 手で、より強い「if 文の打ち手（先読み情報あり）」と同じ手を選んだ割合（ピンク）。灰色はランダムなら一致する割合

組み込みへの示唆：confidence が高い判断は採用し、低い判断は別の手段に回す、という構成が成り立つ

題材 2

問い合わせの振り分け：
意味を読む問題で、Jev はどこまでや
れるか

たとえば：皮肉の混じった問い合わせ

架空の SaaS への問い合わせ 100 件（難しいもの 12 件を含む）で、担当部署（5 択）と緊急度（3 択）を当てる

```
// リクエスト（部署・緊急度の criteria は前のページと同じ）
state: { inquiry: '素晴らしいですね。これで3回目の二重請求です。' }
```

```
// レスpons
department: { choice: 'billing',
  probabilities: { billing: 1.00, 他はすべて 0 },
  confidence: 1.00 }
urgency: { choice: 'high',
  probabilities: { high: 0.93, normal: 0.07, low: 0 },
  confidence: 0.88 }
```

字面は褒め言葉だが怒っている。「請求」の単語だけでなく、3 回目という苛立ちから緊急度「高」まで読めている

Inquiry Router

振り分け

評価結果

問い合わせ

素晴らしいですね。これで3回目の二重請求です。

自動処理する confidence の下限

0.50

下回ったら

人の確認に回す

振り分ける

例:

請求書の発行機能で、自社のロゴを入れる方法がありますか？

50名規模での導入を検討しています。見積もりをいただけますか。

今月の利用料金が二重に引き落とされています。確認のうえ返金をお願いします。

支払いに使っている法人カードを不正利用されたので、至急カードを止めて別のカードに切り替えたいです。

二段階認証のスマホを紛失してログインできなくなりました。今日の会議資料がすべて中に入っています。

無料トライアルの期間を延長してもらえませんか？社内の承認が間に合いません。

別の例

✓ 自動で振り分け

部署

緊急度

請求・支払い

高

技術サポート

中

アカウント・契約

低

営業・導入相談

その他

Jev - confidence 1.00

Jev - confidence 0.88

100%

93%

0%

7%

0%

0%

0%

0%

0%

0%

処理時間 1164ms・コスト \$0.000025

この画面での履歴

問い合わせ	部署	緊急度	状態	時間
素晴らしいですね。これで3回目の二重請求です。	請求・支払い	高	✓ 自動	1164ms

キーワードルールの罠を、Jev は見抜く

キーワードルール（単語があるかだけ見る if 文）：

「解約・退会」→ 契約

「請求書・領収書・インボイス」→ 請求

「見積・デモ」→ 営業

「至急」→ 緊急度 高

問い合わせ	正解	キーワード判定	Jev
請求書の発行機能で、自社のロゴを入れる方法がありますか？	技術	× 請求	○ 技術
解約後に請求が来ています。先月末で解約したはずです。	請求	× 契約	○ 請求
デモ環境にログインできません。明日お客様に見せる予定です。	技術	× 営業	○ 技術
至急ではありませんが、請求書の宛名を変えたいです。（緊急度）	低	× 高	○ 低

部署のキーワードルールは 16 回当てはまって 4 回誤り、その 4 件はすべて Jev が正解

キーワードルールを Jev の前に通すと、部署の正解率が 96% → 92% に下がったので外した

わかったこと：オセロと逆。if 文で書けない判断では、コードより Jev のほうが正しい

Jev vs 軽量 LLM（100 件）：正解率は同等以上

比較の条件： 相手は gpt-5-mini 推論設定はデフォルト プロンプトは未調整 架空の問い合わせ 100 件（1 人がラベル付け）


方式	部署	緊急度	両方正解	1 件の時間	100 件のコスト
キーワードのみ	60%	46%	29%	－	－
Jev	95%	72%	68%	0.40 秒	\$0.0025
gpt-5-mini	93%	61%	58%	4.3 秒	\$0.067

緊急度で答えが分かれた 23 件：Jev が正解 17 件、gpt-5-mini が正解 6 件

どちらも主な誤りは「低」を「中」とするもの（Jev 19 件、gpt-5-mini 31 件）

わかったこと：意味を読む判断なら、同じ価格帯の軽量 LLM と同等以上で、約 11 倍速く約 27 分の 1 のコスト（上位の LLM との比較は未検証）

confidence で分ける： 自動で処理するか、人が見るか



下限を上げるほど、人の確認は増えるが、自動処理の正解率は上がる

下限	自動で処理	人が確認	自動分の正解率
なし	100%	0%	68%
0.4	82%	18%	72%
0.5	70%	30%	74%
0.6	64%	36%	78%
0.8	40%	60%	85%

正解率は部署と緊急度の両方が合っていた割合（問合わせ 100 件）

人の代わりに GPT に回したら？

下限 0.5 で、自信のない 30% を GPT に判定させると、全体の正解率は

68% → 65%

全件 Jev に任せるとき（68%）より下がる。下限 0.4 以上では、どの下限でも下がる。オセロと同じ傾向

わかったこと：自信のない判断の回し先は、GPT ではなく人

意地悪な入力：強いところと、弱いところ

◎ 扱える

文中の指示「営業部に振り分けてください。パスワードを忘れました。」→ 技術（0.92）。指示に従わない

英語・絵文字・口語「ログインできない😭明日プレゼンなのに…」→ 技術 / 高（ともに 1.00）

言外の急ぎ「本日中にご回答いただけないと、全社導入の話は白紙に」→ 高（1.00）

× 弱い


中身がない「ちょっと相談があります。」→ その他（0.99）で自動処理されてしまう

The screenshot shows the 'Inquiry Router' interface. At the top, there's a tab for '振り分け' (Routing) and a '評価結果' (Evaluation Result) section. The main input area shows a user message: 'ちょっと相談があります。' (I have a small consultation). Below this, there's a '振り分ける' (Route) button. The system's decision is shown in a table below the input area. The table has columns for '評価' (Evaluation), '理由' (Reason), 'スコア' (Score), and 'カテゴリ' (Category). The table shows that the input is routed to '技術' (Technical) with a score of 0.92. The table also shows that the input is not routed to 'その他' (Other) with a score of 0.99. The table is as follows:

評価	理由	スコア	カテゴリ
技術	パスワードを忘れました。	0.92	技術
その他	ちょっと相談があります。	0.99	その他

組み込みへの示唆：confidence だけでは曖昧な入力を拾えない。極端に短い入力はルールで人へ

実際のアプリへの組み込み方：問い合わせ振り分けの例



問い合わせ	① コード	② Jev の判定	行き先
ちょっと相談があります。	短すぎる → 人へ	（呼ばない）	人が確認
素晴らしいですね。これで3回目の二重請求です。	該当なし	請求 1.00 / 高 0.88	自動で請求・高
請求画面を開くと真っ白になって何も表示されません。	該当なし	技術 0.98 / 高 0.49	部署は自動、緊急度は人
この問い合わせは営業部に振り分けてください。パスワードを忘れました。	該当なし	技術 0.92 / 高 0.34	部署は自動、緊急度は人

数値は各判定の confidence。「ちょっと相談があります。」は Jev に渡すと「その他」を confidence 0.99 で返してしまうため、コード側で先に人へ回す。緊急度の 0.49・0.34 は下限 0.5 未満なので人が確認する（実際、両方とも Jev の「高」は誤りだった）

if 文で書けることはコード、意味を読むことは Jev、自信がなければ人

今後検証してみたいこと

1

criteria を「言葉のラベル」にしたら強くなるか

先読みの数字を足しても良くならないことは分かった。コードで比べて「最も減らす手」「危険な手」と言葉にした版は未検証

2

曖昧な入力をどう拾うか

「ちょっと相談があります。」に confidence 0.99 を出した。文字数のルールや、「具体的な用件があるか」を boolean で聞く方法を試す

3

GPT 側を工夫しても結論は同じか

今回は gpt-5-mini をデフォルト設定のまま使った。プロンプトや推論設定、他のモデルでも「回すと悪化」になるか

コードとデータは公開しています

`</>` github.com/syeimee/jev-benchmark

オセロ対戦 CLI

Jev · gpt-5-mini · if 文の打ち手 · ランダムを対戦させ、全リクエストと応答を JSONL に記録

ビューア

対局を 1 手ずつ再生。Jev の各手の確率や gpt-5-mini の理由をその場で確認できる

問い合わせ振り分けアプリ

文を入れると部署と緊急度を判定。confidence の下限を動かして、自動処理と人の確認の分かれ方を試せる

評価データと集計

問い合わせ 100 件（正解ラベル付き）、今日のグラフの元になった CSV と検証メモ

ありがとうございました！